MATEMÁTICA APLICADA

ESTADÍSTICA

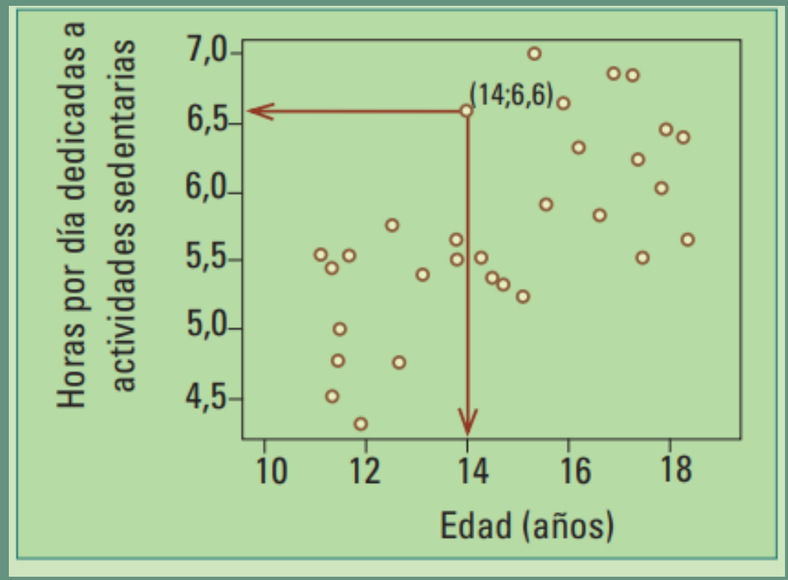
CONTENIDOS NUEVOS

DIAGRAMA DE DISPERSIÓN

La forma gráfica más habitual de describir la relación entre dos variables cuantitativas es utilizando un diagrama de dispersión. Cada punto corresponde a un par de valores (uno para cada variable), medidos sobre el mismo individuo.

En general, si una de las variables puede pensarse como explicativa de la otra (variable explicativa), siempre se la gráfica en el eje horizontal (eje x) y la otra (variable respuesta) en el eje vertical (eje y).

Dos variables están asociadas en forma positiva cuando los valores que están por encima del promedio de una de ellas tienden a ocurrir mayoritariamente con valores por encima del promedio de la otra. Lo mismo ocurre con los que se encuentran por debajo del promedio. Dos variables están asociadas en forma negativa cuando valores por encima del promedio de una suelen estar acompañados por valores por debajo del promedio de la otra y viceversa.



COEFICIENTE DE CORRELACIÓN

Necesitamos un número que no dependa de las escalas del gráfico de dispersión y represente el grado de asociación lineal entre los pares de valores de dos variables continuas.
Un número con todas las propiedades anteriores es el Coeficiente de Correlación de Pearson (r)

$$r = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n} (x_i - \bar{x})^2 \sum_{i=1}^{n} (y_i - \bar{y})^2}}$$

OTRA FORMA DE ESCRIBIR EL COEFICIENTE DE CORRELACIÓN ES:

$$r = \frac{1}{n-1} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{s_x}\right)\left(\frac{y_i - \bar{y}}{s_y}\right)$$

Donde, son los desvíos estándar muestrales de X e Y respectivamente :

$$s_x = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n-1}}$$

$$s_y = \sqrt{\frac{\sum_{i=1}^{n} (y_i - \bar{y})^2}{n-1}}$$

ROPIEDADES DEL COEFICIENTE DE CORRELACIÓN MUESTRAL

PRIMERO

No depende de las unidades en que se miden las variables y su valor está siempre entre -1 y 1.

SEGUNDO

No distingue entre variable explicativa (X) y variable respuesta (Y): el coeficiente de correlación entre X e Y es igual al coeficiente de correlación entre Y y X.

TERCERO

A mayor valor absoluto de r, mayor el grado de asociación lineal.

CUARTO

Cuando r = 0 no hay una tendencia lineal creciente o decreciente en la relación entre los valores x´s e y´s.

QUINTO

Los valores extremos, r = 1 y r = -1, ocurren únicamente cuando los puntos en un diagrama de dispersión caen exactamente sobre una recta. Corresponde a asociaciones positivas o negativas perfectas.

SEXTO

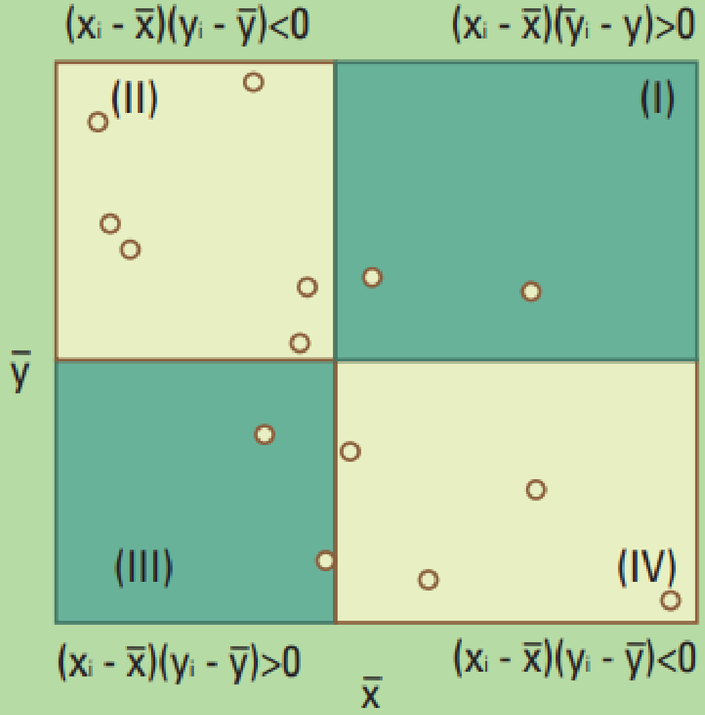
Valores de r cercanos a 1 ó -1 indican que los puntos yacen cerca de una recta.

COMO EL DENOMINADOR DE R ES SIEMPRE POSITIVO

$$\left(\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2\sum_{i=1}^{n}(y_i-\bar{y})^2}\right)$$

PARA COMPRENDER DE DONDE SE OBTIENE SU SIGNO, SÓLO ES NECESARIO ESTUDIAR EL SIGNO DEL NUMERADOR

$$\left(\sum_{i=1}^{n}(x_i-\bar{x})\,(y_i-\bar{y})\right)$$



Cuantos más puntos caigan en los cuadrantes (I) y (III) habrá **más sumandos** de

$$\sum_{i=1}^{n}(x_i-\bar{x})\,(y_i-\bar{y})$$

positivos contribuyendo al total positivo **r > 0**

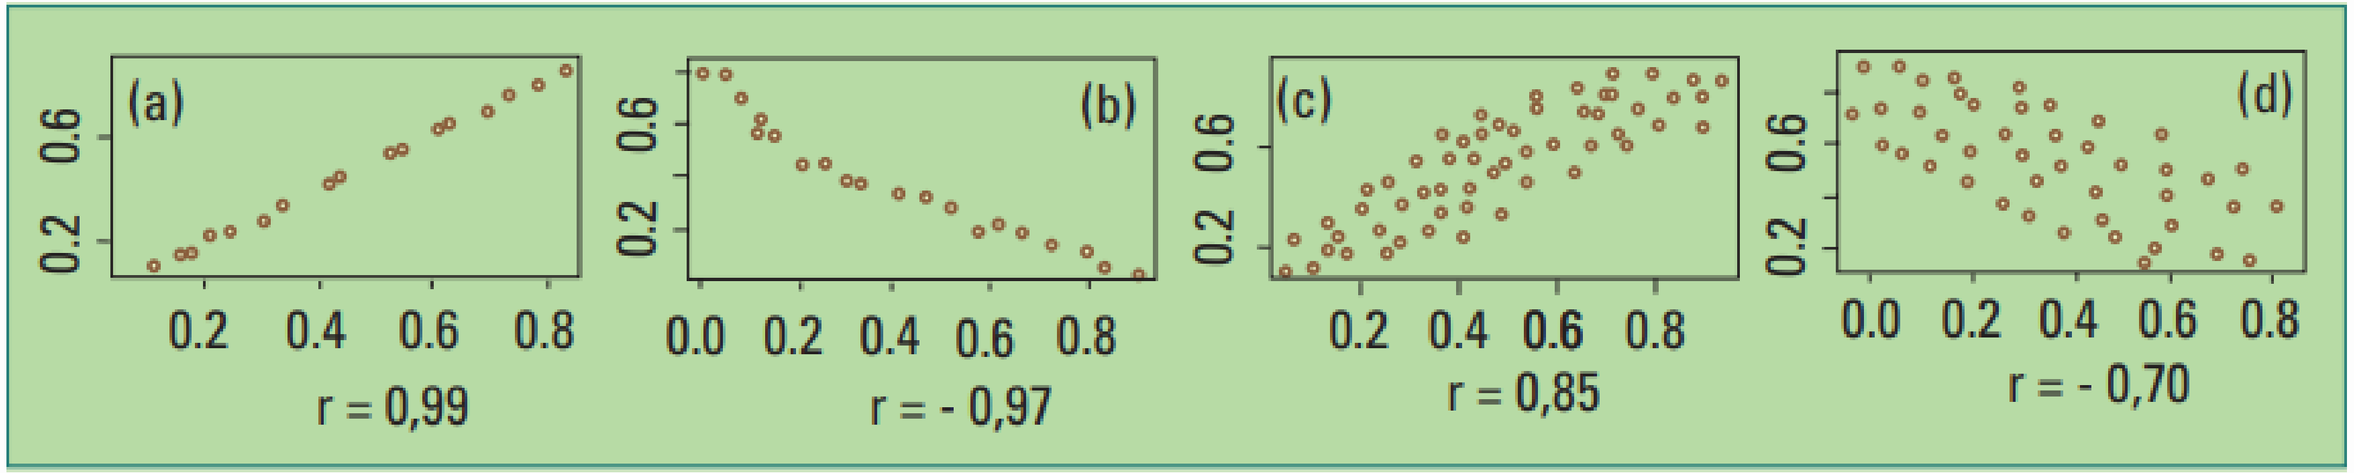
Cuantos más puntos caigan en los cuadrantes (II) y (IV) habrá **más sumandos** de

$$\sum_{i=1}^{n}(x_i-\bar{x})\,(y_i-\bar{y})$$

negativos contribuyendo al total positivo **r < 0**

CONCLUSIÓN

LA FIGURA MUESTRA CÓMO LOS VALORES DE R DECRECEN EN VALOR ABSOLUTO, SE ALEJAN DEL 1 Ó -1, A MEDIDA QUE DECRECE EL GRADO DE ASOCIACIÓN LINEAL ENTRE LAS VARIABLES.



En (a) y (b) se muestran datos con un alto grado de asociación lineal, en el primero la asociación es positiva y en el segundo negativa. En (c) y (d) los datos están menos concentrados sobre una recta pero sigue habiendo claras tendencias: creciente (c) y decreciente (d).

Recta de regresión lineal simple

DEFINICIÓN

Cuando un diagrama de dispersión muestra un patrón lineal es deseable resumir ese patrón mediante la ecuación de una recta. Esa recta debe representar a la mayoría de los puntos del diagrama, aunque ningún punto esté sobre ella.

EJEMPLOS

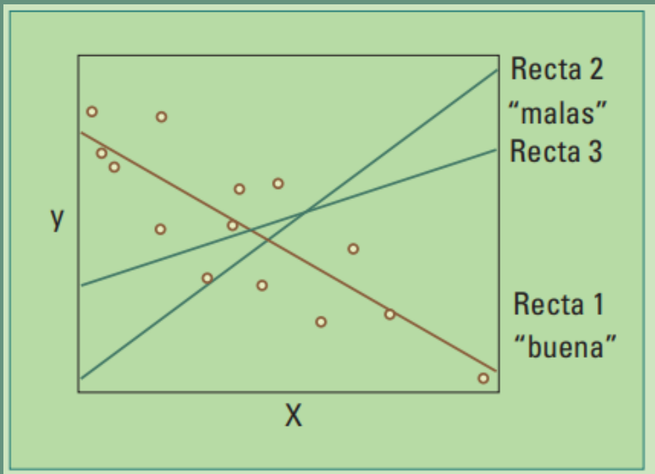


Fig. 22.12. *Tres rectas en un diagrama de dispersión.*

CUADRADOS MÍNIMOS

El método de cuadrados mínimos propone elegir la recta que minimiza la suma de los cuadrados de las distancias verticales de cada punto a la recta (residuos).

Los diagramas de dispersión de la figura muestran los mismos puntos. Las distancias verticales de los puntos a la recta 1 son, en su mayoría, menores que a la recta 2. Por lo tanto la suma de los cuadrados de esas distancias será menor para la recta 1 que para la recta 2

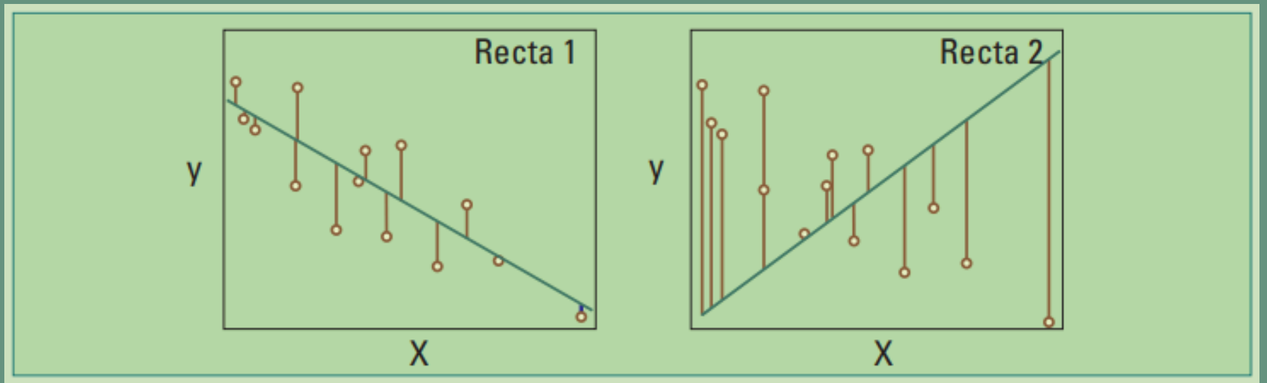


Figura 22.13. *Dos diagramas de dispersión del mismo conjunto de pares de datos y las distancias verticales a dos rectas.*

ANÁLISIS

Consideremos la ecuación de una recta cualquiera y=a+bx.

Sean:

- (xi , yi) las coordenadas de un punto del plano representando al dato i
- (xi , ŷi) las coordenadas de un punto sobre la recta con x = xi

donde ŷ (se lee y sombrero sub i) se obtiene reemplazando xi en la ecuación de la recta ŷi = a+bxi

DISTANCIA VERTICAL DE UN PUNTO (XI , YI) A LA RECTA ES LLAMADA RESIDUO Y SE OBTIENE DE LA SIGUIENTE MANERA:

$$\text{residuo}_i = y_i - \hat{y}_i$$
$$= y_i - (a+bx_i)$$

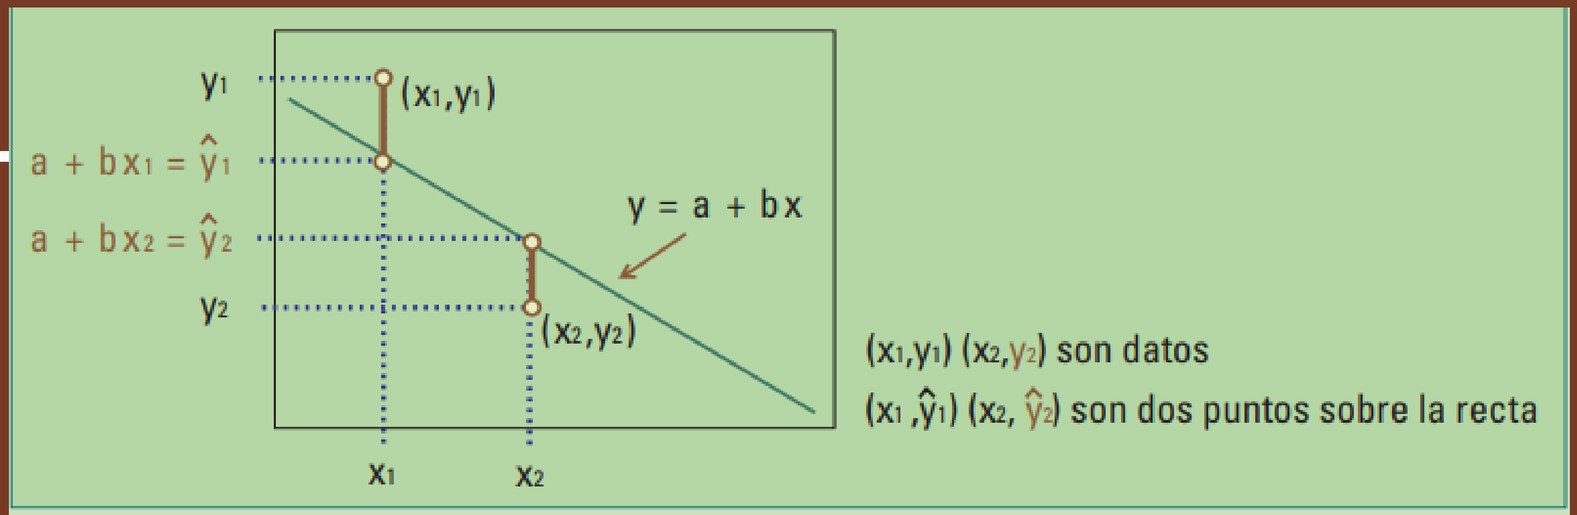
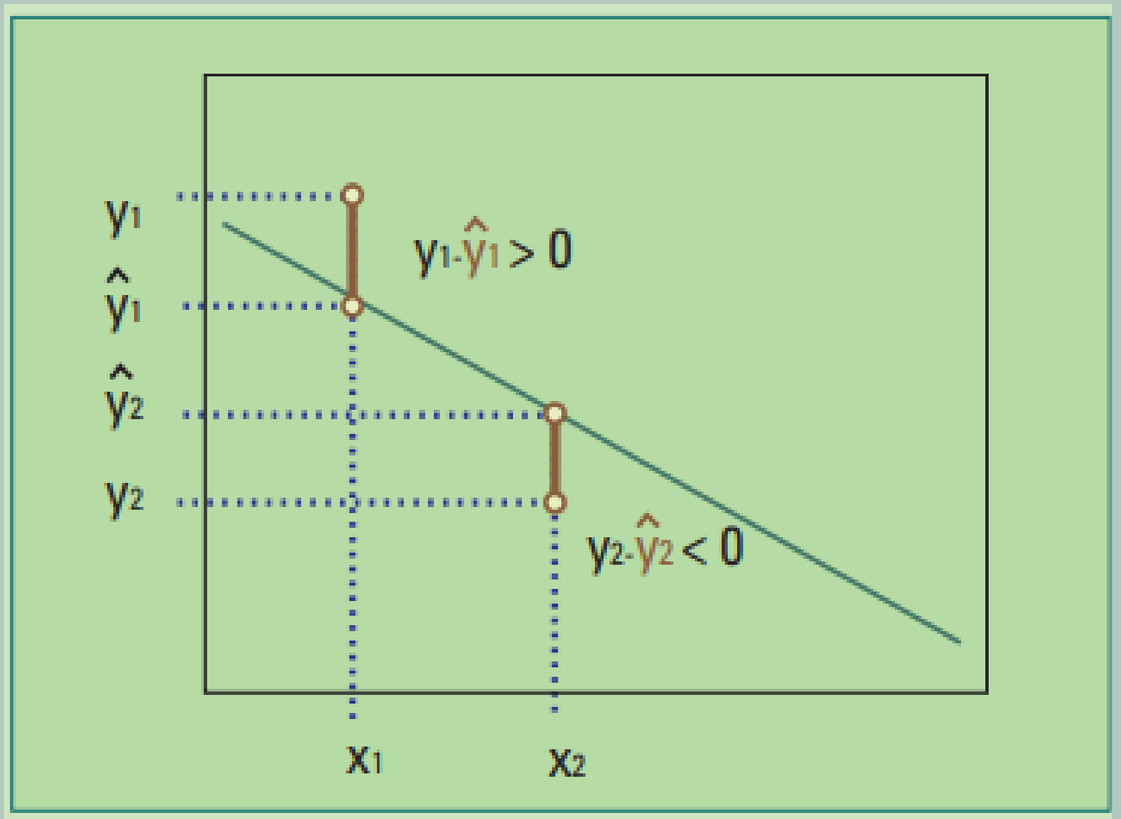


Fig. 22.14. *Dos puntos en el plano y una recta. El primero está por encima de la recta, tiene residuo positivo ($y_1 - \hat{y}_1 > 0$). El segundo está por debajo de la recta, tiene residuo negativo ($y_2 - \hat{y}_2 < 0$).*

RESIDUO



ALGUNOS RESIDUOS SON POSITIVOS, LA RESPUESTA OBSERVADA ESTÁ POR ENCIMA DE LA RECTA, Y OTROS SON NEGATIVOS, LA RESPUESTA OBSERVADA ESTÁ POR DEBAJO DE LA RECTA.

El primer punto se encuentra por encima de la recta

El segundo punto se encuentra por debajo de la recta

¿?

PERO ¿CÓMO HALLAMOS LOS COEFICIENTES A Y B DE LA RECTA QUE MINIMIZA LA SUMA DE LOS CUADRADOS DE LOS RESIDUOS?

Mediante el método de cuadrados mínimos (MC) a y b se eligen de manera que la suma de los cuadrados de los residuos sea mínima.

$$\sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} \left(y_i - (a + b x_i) \right)^2$$

Los coeficientes de la recta estimada por MC se calculan, a partir de los datos, mediante las siguientes ecuaciones:

$$b = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}$$

$$a = \bar{y} - b\bar{x}$$

CONCLUSIÓN

$$b = r \frac{s_y}{s_x}$$

r es el coeficiente de correlación y sx y sy son los desvíos estándar muestrales de las x's y las y's respectivamente.

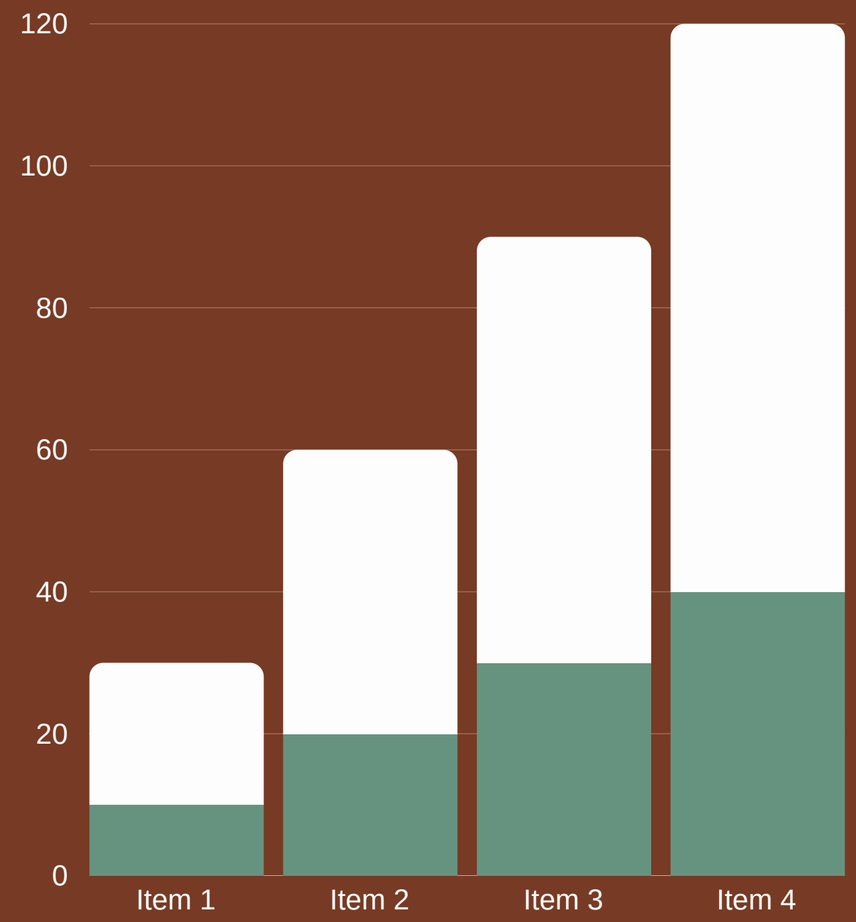
Si sx = sy =1 resulta que la pendiente de la recta ajustada es igual al coeficiente de correlación.

$$a = \bar{y} - b\bar{x}$$

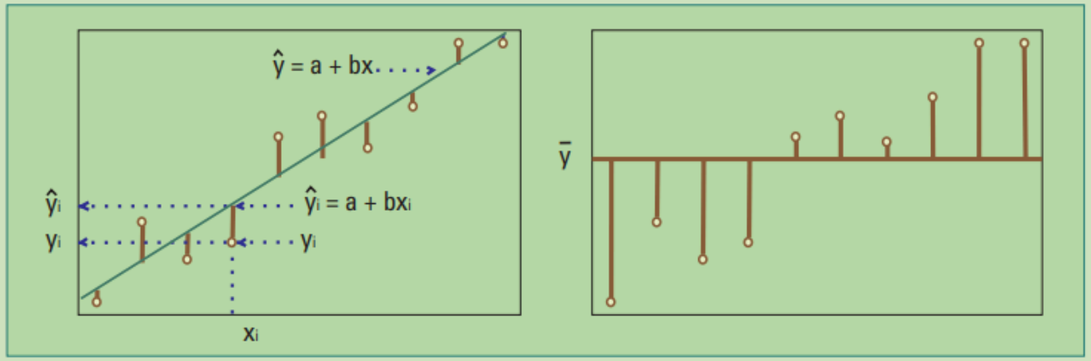
Esto significa que la recta de cuadrados mínimos pasa por el punto $(\bar{x}, \bar{y})$

La suma de los residuos es 0 y equivalentemente su promedio: Si sumamos los residuos, $y_1 - (a+bx_1)$, **, y los dividimos por n entonces,**

$$\frac{\sum_{i=1}^{n} y_i}{n} - \frac{\sum_{i=1}^{n} (a + bx_i)}{n} = \bar{y} - (a + b\bar{x}) = 0$$



COEFICIENTE DE DETERMINACIÓN



22.25. En el gráfico de la izquierda los residuos a la recta ajustada y=a+bx; a la derecha las distancias entre las respuestas observadas y su medida muestral (ȳ).

INTERPRETACIÓN

Los valores observados (yi) están, en general más cerca de ŷi que de ȳ

Los valores observados (yi) tienen una distancia vertical a la recta ajustada (ŷ= a+bx) menor que la recta horizontal de ecuación y = ȳ

CONCLUSIÓN

El coeficiente de determinación, definido a continuación, cuantifica esa reducción.

DEFINICIÓN

El coeficiente de determinación (R^2) mide la proporción en que se reduce la suma de las distancias verticales al cuadrado de los valores observados (xi , yi) alrededor de la recta de cuadrados mínimos en comparación con esas distancias alrededor de la recta de ecuación y = ȳ

FÓRMULA

$$R^2 = \frac{SCT - SCR}{SCT}$$

Suma de cuadrados total SCT. Mide las distancias verticales de los pares observados (xi , yi) a la recta de ecuación y = ȳ

$$SCT = \sum_{i=1}^{n} (y_i - \bar{y})^2$$

SCR es la suma de cuadrados de los residuos:

$$SCR = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

ANÁLISIS

$r^2 = R^2$

El coeficiente de correlación al cuadrado coincide con el coeficiente de determinación

$100 \times R^2$

Es la reducción de la variabilidad de los valores (yi) de la variable respuesta a una recta de regresión lineal y = a+bx en comparación con la variabilidad de los valores (yi) respecto de la recta y = $\bar{y}$.
Decimos que la recta de regresión explica el $100 \times R^2$ de la variabilidad de la variable respuesta.

$R^2 = 0$

Cuando la regresión no explica nada; en ese caso, la suma de cuadrados total es igual a la suma de cuadrados de los residuos.

$R^2 = 1$

Cuando todos los puntos están sobre la recta, la variabilidad observada de la respuesta es explicada totalmente por la regresión y la suma de los cuadrados de los residuos es cero.

GRACIAS POR SU ATENCIÓN

